

Trabajo Práctico 01 - Laboratorio de datos

1er Cuatrimestre - 2025

Grupo: JPG

Integrantes: Julieta Sol Valdez, Pedro Ivan Vicente y Gaspar Urrutia

Profesores: Pablo Guillermo Turjanski, Manuela Ana Cerdeiro y Mateo Guerrero Schmidt

Universidad de Buenos Aires
Facultad de Ciencias Exactas y Naturales
Carrera de Ciencias de Datos

Resumen

Este trabajo se centra en el análisis de datos correspondientes a los departamentos de la República Argentina, con el objetivo de hallar una posible relación entre la cantidad de establecimientos educativos de modalidad común y las bibliotecas populares en cada uno de ellos. Con este fin, realizamos una serie de consultas y visualizaciones a partir de bases de datos que fueron normalizadas y ajustadas a los propósitos del trabajo práctico y su análisis final.

Durante el armado del trabajo, se destacan problemas comunes con la disponibilidad, calidad y formato de los datos públicos brindados, que dificultan su procesamiento. A pesar de ello, los datos, al ser confiables y actuales, permitieron alcanzar los objetivos propuestos. A lo largo del análisis se exploró la posible existencia de correlaciones entre variables. Sin embargo, los resultados obtenidos no permitieron afirmar con claridad una relación directa entre la cantidad de establecimientos educativos y bibliotecas populares en los distintos departamentos del país, incluso al ajustar por población.

A través de cálculos y consultas que se presentarán en las secciones siguientes, se observaron diferencias significativas entre los datos de los departamentos, siendo la Ciudad Autónoma de Buenos Aires el departamento con mayor concentración de establecimientos. Las conclusiones arribadas al finalizar este trabajo permiten reflexionar sobre la distribución de servicios educativos y culturales en el país. Pudiendo observar y comparar según distintas características, tales como el grupo etario de la población, nivel de los establecimientos educativos, fecha de fundación de las bibliotecas, entre otras.

Introducción

El informe presentado tiene como objetivo responder la siguiente pregunta:

¿Existe cierta relación entre la cantidad de bibliotecas populares (BP) y establecimientos educativos (EE) en los departamentos del país?

Para abordarla, se trabajó con tres fuentes de datos abiertas:

- Padrón Oficial de Establecimientos Educativos del año 2022
- Padrón de Bibliotecas Populares
- Datos poblacionales por departamento, extraídos del Censo Nacional 2022

A lo largo del trabajo se planteó un Diagrama de Entidades Relacionales (DER) y su correspondiente modelo relacional, seleccionando y normalizando únicamente los datos relevantes para el análisis.

Además se realizaron tareas de limpieza de las bases de datos. Allí, se extrajo la información relevante, utilizando Python y las bibliotecas Pandas y DuckDB, fundamentales para la comprensión y adaptabilidad hacia nuestro modelo.

Posteriormente, comenzó la etapa del análisis de datos, donde se formularon y ejecutaron diversas consultas SQL. Por último, se generaron visualizaciones con Matplotlib claves para la interpretación de los resultados que fueron obtenidos en el transcurso del trabajo práctico.

A continuación, se detallan las etapas del trabajo, comenzando por el procesamiento de datos.

Procesamiento de datos

Al comenzar el trabajo, se dispuso de tres bases de datos extensas y detalladas. Sin embargo tenían ciertas inconsistencias y problemas de formato que dificultan su análisis.

Establecimientos Educativos

Empezando por la tabla Establecimientos Educativos, si bien es muy rica en información, presenta inconvenientes desde el punto de vista de la normalización. En particular, no cumple con la Primera Forma Normal(1FN), ya que contiene relaciones anidadas (Establecimiento - Localización, Modalidad, etc.).

En cuanto a la calidad de datos, se realizó el siguiente análisis:

1. Compleitud: Los datos están muy completos, es decir que la mayoría de los valores requeridos están presentes. (ver Métricas más adelante). Respecto a las instancias del mundo real, es difícil evaluar la completitud, pero probablemente es el dataset más completo disponible.
2. Relevancia: algunas columnas, como *'talleres-artística'*, *'servicios complementarios'*, *'validez_titulos'* resultan poco útiles para el objetivo de este trabajo. Por otro lado, los datos que necesitamos sí se encuentran en el dataset y están correctamente identificados.
3. Vigencia: Los datos son extremadamente recientes, teniendo poco más de un mes de antigüedad, y considerando que las instancias reales representadas tardan mucho tiempo en modificarse.
4. Disponibilidad: Hay varios problemas con la accesibilidad de los datos.
 - Su estructura original cuenta con 11 filas iniciales fuera de la tabla que interfieren a la hora de leerlo en algún programa de visualización de bases de datos como Pandas.
 - Las columnas a la derecha de Modalidad (inclusive) tienen un formato que puede llegar a hacer difícil su lectura. Por ejemplo, si queremos conocer la modalidad de un establecimiento educativo tenemos que recorrer las 3 columnas (común, especial, adultos). Una alternativa más clara podría ser normalizar este atributo con una única columna denominada "Modalidad", en especial teniendo en cuenta que las 3 categorías son exclusivas.
5. Confiabilidad: Al tratarse de datos provistos por el Estado, se asume confiabilidad.
6. Consistencia: Existen riesgos de inconsistencia en algunas columnas. Por ejemplo, si llegara a haber un error o una mala inserción que provocase que dentro de Modalidad se escribiera un 1 en dos columnas distintas, habría una contradicción en la base de datos, lo cual representa una debilidad del modelo.
7. Corrección: No se hallaron errores evidentes por lo que se puede suponer que los datos son correctos.

8. Seguridad/Privacidad: Todos los datos que figuran en la tabla son de acceso público, por lo que no debería haber ningún problema en su publicación.

Análisis de Métricas


Para esta fuente de datos nos propusimos medir la completitud. Se aplicó el método GQM.

- Goal: Que la información correspondiente a modalidad esté completa para todos los establecimientos.
- Question: ¿Están todos los datos sobre modalidad en el dataset?
- Metric: Proporción de filas con un 0 / null en el apartado Modalidad.

Para llevar a cabo esta evaluación, se utilizó el siguiente código en Pandas:

```
establecimiento_sin_modalidad = ee[(ee['Común'].isnull()) & (ee['Especial'].isnull()) & (ee['Adultos'].isnull())]
```

resultado:



```
In [106]: %run cell -n 'metrica ee' C:/Users/User/Desktop/laboratorio/visual.py
```

	Jurisdicción	Sector	...	Unnamed: 38	Unnamed: 39
53	Ciudad de Buenos Aires	Estatal	...	1.0	NaN
155	Ciudad de Buenos Aires	Estatal	...	1.0	NaN
843	Ciudad de Buenos Aires	Estatal	...	1.0	NaN
1044	Ciudad de Buenos Aires	Estatal	...	1.0	NaN
1763	Ciudad de Buenos Aires	Estatal	...	1.0	NaN
...	...	...	...	...	...
64661	Tierra del Fuego	Estatal	...	NaN	NaN
64662	Tierra del Fuego	Estatal	...	NaN	NaN
64705	Tierra del Fuego	Estatal	...	1.0	NaN
64706	Tierra del Fuego	Estatal	...	1.0	NaN
64707	Tierra del Fuego	Estatal	...	1.0	NaN

[2032 rows x 40 columns]

Imagen 1: consulta para medir los establecimientos sin modalidad

Esta consulta identificó 2.032 filas sin información de modalidad, sobre un total de 64.713 establecimientos. Esto representa cerca del 3% de los establecimientos.

Este porcentaje es relativamente bajo e indica que, en general, los datos están muy completos. Incluso, observando en detalle estos casos específicos, se observó que la mayoría, por no decir todos, son de modalidad hospitalaria, talleres, artísticos, etc. El problema, entonces, reside en el modelo. Ya que no tiene definida una modalidad para estos establecimientos. Se podría resolver incluyendo una columna "Hospitalaria", otra "Talleres", etc. dentro de la sección modalidad.

Bibliotecas Populares

La segunda fuente de datos utilizada en este trabajo corresponde al Padrón de Bibliotecas Populares. Desde el punto de vista de la normalización, se puede afirmar que cumple con la Primera Forma Normal (1FN), ya que no presenta relaciones anidadas ni valores múltiples. Sin embargo, no cumple con la Segunda Forma Normal (2FN), ya que, tomando la clave candidata {nombre, domicilio}, la columna CP (código postal) depende parcialmente del domicilio.

En cuanto a la calidad de datos, se realizó el siguiente análisis.

1. Complejidad: Los datos no están muy completos. Se identifican múltiples columnas con mucha cantidad de valores nulos. Por ejemplo, en la columna "mail" hay varias bibliotecas en las que no se especifica. En este caso creemos que puede ser un problema de instancia, que si bien es posible que haya bibliotecas para las que no se cargó el mail, también es posible que algunas simplemente no cuenten con uno. Lo mismo sucede en las columnas teléfono y cod_tel.
2. Relevancia: Se encuentran varias columnas que son casi o totalmente irrelevantes. Las columnas Observación, Subcategoría, web, Información Adicional y Piso están completamente vacías. Todos sus valores son nulos. Por otro lado, las columnas Tipo latitud longitud, Fuente y Categoría tienen todos sus valores idénticos. Por lo tanto se podría decir que no aportan información útil y podrían ser descartadas.
3. Vigencia: Si bien los datos tienen ya más de medio año de antigüedad, consideramos que son recientes teniendo en cuenta que la inauguración de bibliotecas populares no es un fenómeno frecuente. Por lo tanto, los datos pueden seguir siendo representativos de la situación actual.
4. Disponibilidad: La tabla es de fácil lectura en general, pero presenta inconsistencias en campos como el nombre del departamento. Se observan abreviaciones, omisión de tildes y diferencias en la denominación respecto de otras fuentes.
5. Confiable: Al tratarse de datos provistos por el Estado, se asume confiabilidad.
6. Consistencia: Se observaron inconsistencias en los datos, en especial en la dependencia entre id_departamento y departamento. Se encontraron tanto departamentos distintos con el mismo id, como departamentos que figuran con id's distintos a pesar de ser el mismo. Como ejemplo podemos poner: en las filas 17 y 18, el departamento Almirante Brown figura primero con id 6028 y luego con id 6427.
- 7.

6028		Biblioteca Popular		Buenos Aires	Almte Brown
6427		Biblioteca Popular		Buenos Aires	Almte Brown

Imagen 2: Caso donde hay un departamento con mismo nombre de departamento pero distinto id

Para ejemplificar el otro tipo de inconsistencia en los ids, podemos ver que con el id 6028 figuran los departamentos Almirante Brown, Merlo y Quilmes.

6028		Biblioteca Popular		Buenos Aires	Almte Brown
6028		Biblioteca Popular		Buenos Aires	Merlo
6028		Biblioteca Popular		Buenos Aires	Quilmes

Imagen 3: Caso donde hay departamentos con distintos nombres de departamento pero mismo id

```
In [40]: %run cell -n jajajaj C:/Users/User/Desktop/laboratorio/visual.py
6021 ['Alberti' 'Bragado']
6028 ['Almte Brown' 'Merlo' 'Quilmes']
6427 ['Almte Brown' 'La Matanza']
6091 ['Berazategui' 'Quilmes']
6182 ['Cnel De Marina L Rosales' 'Coronel Rosales']
6476 ['Lincoln' 'Loberia']
6560 ['Moreno' 'Moron']
10063 ['Fray Mamerto Esquiú' 'Santa Maria']
10084 ['Poman' 'Sin Partido']
10091 ['Santa Maria' 'Tinogasta']
26021 ['Escalante' 'Sin Partido']
14091 ['Capital' 'Punilla' 'Sin Partido']
14021 ['Colon' 'Rio Primero']
14098 ['Rio Cuarto' 'Sin Partido']
14119 ['Rio Segundo' 'Sin Partido']
30056 ['Gualeguaychu' 'Sin Partido']
38021 ['Dr Manuel Belgrano' 'Sin Partido']
38014 ['El Carmen' 'Sin Partido']
42035 ['Conhelo' 'Sin Partido']
42154 ['Sin Partido' 'Utracan']
```

Imagen 4: Consulta para identificar los id_departamento duplicados

8. Corrección: es difícil evaluarla, pero al ser datos confiables y relativamente vigentes, podemos suponer que son correctos.
9. Seguridad: Todos los datos que figuran en la tabla son de acceso público, por lo que no debería haber ningún problema en su publicación.

Análisis de Métricas

Para esta fuente de datos se propuso medir la relevancia de los datos. Como ya se mencionó previamente, la tabla contiene varias columnas con datos que no aportan ninguna información.


Utilizamos el enfoque GQM:

- Goal: que no haya ninguna columna irrelevante.
- Question: ¿todas las columnas de nuestra tabla tienen información relevante?
- Metric: contar qué porcentaje de columnas tienen todas sus entradas nulas o iguales entre sí.


Hay un total de 25 columnas y al contar las columnas irrelevantes (todos valores nulos o iguales entre sí), dió un total de 9 y estas son: 'Observación', 'Categoría', 'Subcategoría', 'Piso', 'Web', 'Información Adicional', 'Tipo Latitud Longitud', 'Fuente' y 'Año de actualización'. (Para mayor seguridad fue chequeado con Pandas columna por columna). Esto nos da un porcentaje de 36% de columnas irrelevantes. Lo que indica que más de un tercio de las celdas de la tabla no aportan información relevante.

El problema es atribuible al modelo, ya que no tiene ningún sentido almacenar estos datos. Por eso, más adelante, como acción de mejora, durante la etapa de limpieza de datos, se procedió a eliminar estas columnas.

Documentación del DER



Representación en el modelo relacional



Limpieza de datos

Como ya se dijo anteriormente, para este trabajo se utilizaron tres fuentes de datos públicas. El fin de esta etapa del trabajo fue transformar los archivos originales en

estructuras más accesibles, eliminando datos irrelevantes, normalizando columnas claves y organizando la información de manera que nos facilite el análisis posterior.

Mediante una exploración preliminar de los datos, se identificó que el elemento en común entre las tres fuentes es que todas referencian de alguna forma el departamento. Esto permitió establecer al id departamento como la clave principal para combinar las diferentes tablas.

Bibliotecas Populares

La limpieza comenzó por el archivo Bibliotecas Populares, originalmente en formato CSV.

Se seleccionaron las columnas relevantes de acuerdo con el modelo definido en el DER:

'id_departamento', 'mail' y 'fecha_fundacion'. Para contar con un identificador único para las bibliotecas se utilizó el índice original del DataFrame. En cuanto a la fecha de fundación, se extrajo únicamente el año, recortando los primeros cuatro caracteres del campo que originalmente contenía el formato año-mes-día.

También se procesó la columna 'mail' para extraer solamente el dominio del correo electrónico, mediante una función que recorría la columna y para cada fila elimina el resto del texto.

Finalmente, tanto el campo id_departamento como el año de fundación fueron convertidos a tipo str para facilitar su manejo posterior.

Luego, se obtuvo la tabla bibliotecas_populares con las columnas:

'id', 'id_departamento', 'dominio_mail', 'año_fundacion'.

Provincia

A partir de este mismo archivo, se generó la tabla provincia, extrayendo las columnas

'id_provincia' y 'provincia', renombrándolas como 'id' y 'nombre' respectivamente. También en este caso se convirtió 'id_provincia' a tipo str.

Tabla de Niveles

Antes de indagar en los archivos de establecimientos y población, se construyó

manualmente la tabla nivel, que asigna un identificador único a cada nivel educativo

relevante para el análisis: jardín, primaria y secundaria. Esta tabla fue creada a partir de un diccionario en Python.

Establecimientos Educativos

El archivo original de establecimientos educativos (en formato .xlsx) resultó particularmente complejo de procesar. Las primeras filas (hasta la fila 12) fueron descartadas para acceder a la tabla real.

Del total de las filas se filtraron solo aquellos pertenecientes a la modalidad común (columna común = 1 en la original). Se seleccionaron columnas relevantes: 'Código de departamento', 'Departamento', 'Cueanexo', 'Nivel inicial - Jardín de Infantes', 'Primario', 'Secundario' y 'Secundario - INET'.

Con estas columnas se construyó el DataFrame 'establecimientos_educativos'.

Luego, se creó la tabla 'niveles_x_establecimiento', que contiene dos columnas: 'Cueanexo' y 'nivel'. Para ello, se recorrió cada fila del DataFrame, identificando los niveles que ofrecía cada establecimiento asignándole el identificador definido en la tabla de niveles.

Una vez ya creada esta tabla intermedia, 'establecimientos_educativos' fue simplificada conservando solo las columnas 'Cueanexo', 'id_departamento'.

Padrón Población

Presenta una estructura atípica. No consiste en una tabla continua, sino que en varias separadas por bloques. Cada una representando un departamento con su población detallada por edad y al final su población total.

Se implementó un bucle que recorría el inicio de cada tabla y extraía la información necesaria: población entre 1 y 5 años (población jardín), población entre 6 y 12 años (población primaria), población entre 13 y 18 años (población secundaria) y la población total.

Los datos fueron almacenados inicialmente en un diccionario con listas por cada nivel. Luego, se creó la tabla 'población_x_depto', que contiene el id_departamento, y sus respectivas poblaciones mencionadas anteriormente.

Para completar, a partir de este DataFrame se creó la tabla 'Departamento'. De esta tabla se obtuvo el nombre del departamento y su id, y de la tabla Provincia se obtuvo su id_provincia.

Se detectaron algunas inconsistencias con los identificadores de departamentos (especialmente en CABA) las cuales requirieron un trabajo manual para su corrección y tomar ciertas decisiones sobre la información que quedaba.

Decisiones tomadas

A lo largo del trabajo práctico se debieron tomar diversas decisiones importantes en el tratamiento y estructuración de los datos.

Una de las primeras decisiones fue separar los niveles educativos en una tabla independiente. Como un mismo establecimiento puede ofrecer más de un nivel (por ejemplo jardín y primaria en simultáneo), se optó por generar una tabla que contuviera una fila por cada combinación entre establecimiento y nivel ofrecido. Esta estructura refleja correctamente la relación muchos a muchos entre establecimiento y niveles educativos. Al definir qué niveles y modalidades incluir, se decidió trabajar exclusivamente con los establecimientos de modalidad común, tal como lo establece el enunciado del trabajo práctico. También se incorporaron los establecimientos etiquetados como 'Secundario - INET', por tratarse de secundarios técnicos que consideramos parte del sistema educativo "común". En cambio, se excluyeron las siguientes columnas del análisis: 'Nivel inicial - Jardín maternal', "SNU", "SNU - INET", "SNU - Cursos" (por corresponder a institutos superiores no universitarios), y modalidades hospitalarias, talleres artísticos y servicios complementarios.

En relación a los nombres y códigos de los departamentos, se detectaron numerosas inconsistencias entre las distintas tablas. En algunos casos, el mismo departamento aparecía con nombres diferentes (por ejemplo, "Almirante Brown" en unas tablas y "Almte Brown" en otras). También se identificaron diferencias en los identificadores, e incluso estructuras distintas en su modelado, como en el caso de la Ciudad de Buenos Aires, que aparece dividida en comunas en el padrón de población y en establecimientos educativos, pero no en la base de bibliotecas populares.

Para resolver estas diferencias y unificar los datos, se decidió tomar como referencia principal la información de la tabla Padrón Población, ya que contiene un listado completo y coherente de departamentos con identificadores únicos. En consecuencia, se eliminaron los nombres de departamento en las tablas de bibliotecas populares y establecimientos

educativos, de modo que al realizar la combinación (merge) entre fuentes, se obtiene el nombre desde la tabla de departamentos estandarizada.

Esta decisión permitió mantener la consistencia en las uniones, evitar duplicaciones innecesarias y facilitar los análisis posteriores. Para ilustrar este proceso, se incluye en el script de procesamiento un ejemplo concreto con código, que muestra cómo se resolvieron estas discrepancias:

```
Out[26]:
```

	departamento	...	nombre
0	Ciudad Autónoma de Buenos Aires	...	CABA
43	Adolfo Gonzalez Chaves	...	Adolfo Gonzales Chaves
45	Bragado	...	Alberti
46	Almte Brown	...	Almirante Brown
54	Merlo	...	Almirante Brown
..	...	...	...
352	Gral Taboada	...	General Taboada
355	Juan F Ibarra	...	Juan Felipe Ibarra
356	Copo	...	Ojo de Agua
357	Sin Partido	...	Chicligasta
358	Sin Partido	...	Trancas

[123 rows x 4 columns]

Imagen 5: Consulta utilizada para observar diferencias en los nombres de departamento entre la tabla departamento y bibliotecas populares.

Esta consulta devuelve un JOIN entre la tabla bibliotecas (izquierda) y departamento (derecha), mostrando los departamentos que tienen nombres distintos. Podemos ver que hay bastantes diferencias. Pero si tomamos, por ejemplo, la inconsistencia Iriondo/San Lorenzo:

	id_departamento	departamento	dominio_correo	id	anio_fundacion
1643	82119	Iriondo	yahoo	1643	1924
1757	82119	San Lorenzo	hotmail	1757	1977
1758	82119	San Lorenzo	arnet	1758	1917
1759	82119	San Lorenzo	gmail	1759	1939
1760	82119	San Lorenzo	None	1760	1920
1761	82119	San Lorenzo	None	1761	1980
1762	82119	San Lorenzo	None	1762	1918

Imagen 6: Consulta para analizar específicamente el caso San Lorenzo, Iriondo

Vemos que la mayoría de las bibliotecas con id 82119 figuran en San Lorenzo. Esto se repite para varios otros casos.

Si comparamos los ID en la tabla establecimientos con los de departamento vemos que la coincidencia es prácticamente total:

```
Out[24]:
```

	Departamento	...	nombre
0	CAÑUELAS	...	Canuelas
98	CORONEL DE MARINA L ROSALES	...	Coronel de Marina Leonardo Rosales
165	PRESIDENTE ROQUE SAENZ PEÑA	...	Presidente Roque Saenz Pena
232	MAYOR LUIS J FONTANA	...	Mayor Luis J. Fontana
315	O HIGGINS	...	O'Higgins
371	15 DE MAYO	...	1o de Mayo
397	LANGUINEO	...	Languineo
408	PATÍÑO	...	Patino
710	DOCTOR MANUEL BELGRANO	...	Dr. Manuel Belgrano
932	CORONEL FELIPE VARELA	...	General Felipe Varela
956	GENERAL ANGEL V PEÑALOZA	...	Angel Vicente Penalzoa
981	GENERAL JUAN F QUIROGA	...	General Juan Facundo Quiroga
1012	GENERAL OCAÑO	...	General Ortiz de Ocampo
1054	ROSARIO VERA PEÑALOZA	...	Rosario Vera Penalzoa
1100	LIBERTADOR GRL SAN MARTIN	...	Libertador General San Martin
1222	AÑELO	...	Anelo
1241	NORQUIN	...	Norquin
1259	NORQUINCO	...	Norquingo
1271	LA VIÑA	...	La Vina
1281	GENERAL JUAN MARTIN DE PUEYRREDON	...	Juan Martin de Pueyrredon
1448	LIBERTADOR GRL SAN MARTIN	...	Libertador General San Martin
1497	JUAN F IBARRA	...	Juan Felipe Ibarra
1563	JUAN B ALBERDI	...	Juan Bautista Alberdi
1599	ANTARTIDA ARGENTINA	...	Antártida Argentina

[24 rows x 4 columns]

Imagen 7: Consulta útil para la comparación de nombre departamento entre las tablas de Establecimientos Educativos.

Las diferencias se deben a diferencias en el formato.

Una excepción importante a la unificación por `id_departamento` se presentó en el caso de las Comunas de la Ciudad Autónoma de Buenos Aires. En este caso, se optó por utilizar los identificadores presentes en la tabla de establecimientos educativos, ya que tenían un formato consistente y sistemático (21 seguido del número de comuna), a diferencia de los identificadores del padrón poblacional.

Por otro lado, se detectó que las bibliotecas populares localizadas en CABA no incluían especificación de comuna ni coincidían con los identificadores utilizados en las otras fuentes. Para poder integrarlas correctamente al análisis, se agregó manualmente la fila `['2000', 'CABA', '2']` a la tabla de departamentos. Esta fila representa a toda la Ciudad Autónoma de Buenos Aires como una única unidad departamental, lo que permitió cruzar los datos de bibliotecas sin perder registros.

Además, se corrigieron manualmente los identificadores de algunas localidades de Tierra del Fuego, cuyos valores no coincidían con los presentes en la tabla unificada de departamentos. Todas estas correcciones fueron aplicadas también a la tabla `población_x_depto`, asegurando la coherencia en todas las combinaciones y consultas posteriores.

Análisis de Datos

Consultas SQL

Consulta 1: Nos pide detallar todos los departamentos, con su población dividida según el nivel educativo, con la cantidad de establecimientos de cada nivel. La tabla está incluida en el anexo con el nombre `depto_x_grupo_etario.csv`

Trabajo Práctico 01 - Laboratorio de Datos - 1er Cuatrimestre 2025
JPG - Julieta Valdez, Pedro Vicente, Gaspar Urrutia

Provincia	Departamento	Jardines	Población Jardín	Primarias	Población Primaria	Secundarios	Población Secundaria
Buenos Aires	La Matanza	333	135713	335	225872	336	181212
Buenos Aires	La Plata	218	45039	201	77998	211	67326
Buenos Aires	Lomas de Zamora	168	44132	179	76967	191	65257
Buenos Aires	General Pueyrredon	177	35638	168	62565	173	57730
Buenos Aires	Quilmes	158	41168	145	70881	151	60085

Imagen 8: Resultado que arroja la consulta SQL número 1

De esta consulta podemos concluir que no hay una gran correlación entre la población de un grupo etario y la cantidad de establecimientos educativos que enseñan en ese nivel. La siguiente figura muestra la cantidad de escuelas primarias por cada mil habitantes.

```
In [121]: a.sort_values()
Out[121]:
97      1.312517
0       1.483141
25      1.488799
12      1.520441
58      1.621364
...
399     63.829787
141     83.832335
507           NaN
508           NaN
510           NaN
Length: 528, dtype: float64
```

Imagen 9: Muestra de cantidad de escuelas primarias por cada mil habitantes.

Estos resultados, refuerzan lo dicho anteriormente. Dado que si existiera una correlación entre población y cantidad de establecimientos, las escuelas primarias por cada mil habitantes flotarían alrededor de un rango determinado. De esto podríamos concluir que la inversión en educación no es equitativa si comparamos los distintos departamentos del país.

Consulta 2: Nos pide detallar la cantidad de bibliotecas populares inauguradas desde 1950 en cada departamento. La tabla se encuentra en el anexo con el nombre bibliotecas_desde_1950.csv

Provincia	Departamento	Cantidad de BP fundadas desde 1950
Buenos Aires	La Plata	15
Buenos Aires	La Matanza	15
Buenos Aires	Moreno	13
Buenos Aires	Tigre	12

Imagen 10: Muestra la tabla pedida en la consulta 2.

Esta consulta nos permite concluir que la gran mayoría de las bibliotecas populares, 1253 de 1902 (es decir el 65%), fueron inauguradas después de 1950.

Trabajo Práctico 01 - Laboratorio de Datos - 1er Cuatrimestre 2025
JPG - Julieta Valdez, Pedro Vicente, Gaspar Urrutia

```
sum(bibliotecas_desde_1950['Cantidad de BP fundadas desde 1950'])
1263
```

Imagen 11: Métrica que indica el tamaño de la tabla resuelta (es decir la cantidad de BP fundadas desde 1950)

Consulta 3: Nos pide detallar la cantidad de establecimientos educativos y de bibliotecas populares en cada departamento, junto con la población total. La tabla se encuentra en el anexo con el nombre ee_bp_x_depto.csv

Provincia	Departamento	Cant_EE	Cant_BP	Población
Ciudad Autónoma de Buenos Aires	CABA	1594	43	6.19091e+06
Córdoba	Capital	1064	20	1.49806e+06
Buenos Aires	La Matanza	969	16	1.83717e+06
Santa Fe	Rosario	754	39	1.33796e+06
Buenos Aires	La Plata	619	33	756074

Imagen 12: Resultado de la consulta SQL numero 3

De esta consulta se puede ver en primer lugar que hay muchos más establecimientos educativos que bibliotecas populares. Por otro lado, podemos ver que no hay una mayor correlación entre estas dos cantidades, habiendo departamentos con muchos establecimientos y pocas bibliotecas, y viceversa. Sí podemos ver que la población total tiene una relación con ambas cantidades.

Consulta 4: Nos pide encontrar el dominio de correo más usado por las bibliotecas populares de cada departamento. La tabla se encuentra en el anexo con el nombre correos_bp_x_depto.csv

Provincia	Departamento	Dominio más frecuente en BP
Buenos Aires	Monte	hotmail
Buenos Aires	Roque Perez	yahoo
Buenos Aires	General Lavalle	hotmail
Buenos Aires	Villarino	yahoo
Buenos Aires	Trenque Lauquen	yahoo
Buenos Aires	Canuelas	YAHOO
Buenos Aires	Coronel de Marina Leonardo Rosales	gmail

Imagen 13: Resultado que arroja la consulta 4.

De esta consulta podemos concluir que las bibliotecas tienen un gran retraso en su tecnología. Ya habíamos visto que muchas bibliotecas no tienen correo electrónico en el análisis de calidad. Esta consulta además nos muestra que en la mayoría de los departamentos el dominio más usado no es gmail. Abundan los departamentos con yahoo, hotmail o live como dominio más usado.

Visualizaciones

Gráfico 1: Nos pide la cantidad de bibliotecas populares por provincia. No sorprende que Buenos Aires encabece la lista, al ser la más poblada. Sí sorprende quizás que CABA esté tan abajo. Se observan tres grupos de provincias: Buenos Aires, Santa Fe, y Córdoba lideran la lista con mucha diferencia respecto de las demás provincias (también forman el grupo de las más pobladas). Abajo de todo vemos a Tierra del Fuego, Santa Cruz, La Rioja, Formosa. ii) Graficar la cantidad de EE de los departamentos en función de la población, separando por nivel educativo y su correspondiente grupo etario (identificándolos por colores). Se pueden basar en la primera consulta SQL para realizar este gráfico. Son provincias con población muy baja, por lo que no es raro verlas al final de la lista. En medio se encuentran una gran cantidad de provincias que tienen una cantidad similar de bibliotecas de alrededor de 60/70.




Imagen 14: Visualización para la consigna i)

Gráfico 2: Nos pide graficar la cantidad de establecimientos de los departamentos en función de la población por grupo etario, identificando según el color el nivel educativo al que pertenece. Se ve un claro comportamiento: A medida que aumenta la población, aumenta la cantidad de establecimientos educativos. A pesar de eso hay departamentos que no siguen el mismo patrón y se alejan de los resultados que uno esperaría ver si se observa solo la población.




Imagen 15: Visualización para la consigna ii)

Gráfico 3: Se realizó un boxplot por cada provincia, donde las muestras son la cantidad de establecimientos educativos por cada departamento de la provincia.




Imagen 16: Visualización para la consigna iii)

Lo primero que observamos fue la diferencia en la cantidad de outliers y los rangos de las distintas provincias. Asociamos el rango de una provincia a su centralización; una provincia con un rango pequeño es una provincia homogénea, donde todos los departamentos tienen cantidades similares de Establecimientos, mientras que una provincia con un rango muy grande es una que presenta un grupo de departamentos significativamente más poblados que la mayoría de los departamentos (en términos de Establecimientos). Aquí Buenos Aires representa un caso interesante por su gran cantidad de outliers. Lo asociamos a que es una

provincia con muchos “centros” que sacan diferencia con el resto de la provincia, frente a otras provincias que tienen uno o dos. Notamos tres outliers que además son los máximos del dataset: Córdoba Capital, La Matanza y Rosario.

Gráfico 4: Este gráfico nos permitió arribar a la conclusión de la pregunta principal que hace el TP. Concluimos que no se observa una correlación fuerte entre BP y EE. Hay muchos departamentos con pocas o nulas BP, independientemente de la cantidad de EE. Hay departamentos con muchas BP y no tantas EE, y vice versa. Lo que sí notamos es que en general la cantidad de establecimientos educativos es mayor a la de bibliotecas populares.




Imagen 17: Visualización para la consigna iv)

Conclusiones

En el transcurso del trabajo se analizaron los padrones de establecimientos educativos de modalidad común, bibliotecas populares y población por departamento, con el objetivo de hallar una posible relación entre la cantidad de EE y BP en un mismo departamento.

Al comenzar el análisis, partimos de la hipótesis de que existía una relación clara entre la cantidad de establecimientos educativos y bibliotecas populares en los distintos departamentos del país, dado que esperábamos que la presencia de servicios educativos y cultural podrían estar vinculados. Sin embargo, a medida que avanzamos en los análisis, consultas y visualizaciones, los resultados no arrojaron una correlación evidente, ni siquiera al ajustar por población. Esto nos llevó a revisar nuestras suposiciones iniciales. Si bien se identificaron algunas tendencias generales (como departamentos con gran cantidad de establecimientos educativos y bibliotecas), el análisis llevado a cabo no mostró una relación directa entre ambas.

Esto se mostró principalmente en el gráfico de dispersión final (explicado anteriormente). Además, se identificaron limitaciones en los datos utilizados, en particular inconsistencias en los identificadores de departamento y diferencias en la estructura de los departamentos en los diferentes archivos brindados (por ejemplo CABA dividida en comunas en algunas tablas y en otras no).

A pesar de estas limitaciones, se permitió generar una base de datos limpia y bien estructurada, y ofreció una visión útil sobre la distribución de los establecimientos educativos y las bibliotecas populares en el país.